

第 7 章教学要求:

1. 理解点估计的概念, 掌握矩估计法与最大似然估计法.
2. 了解无偏性、有效性、一致性等点估计量的评价准则.
3. 理解区间估计的概念, 会求单个正态总体均值与方差的置信区间, 会求两个正态总体均值差与方差比的置信区间.

第 7 章 参数估计

在研究总体时, 经常会面对这样的问题: 总体的分布已知, 但分布中有未知参数, 而为了研究总体, 需要知道这些参数. 研究如何用样本所提供的信息来估计未知参数 (也说未知参数的真值), 即是参数估计问题. 参数估计有两种基本形式: 点估计和区间估计.

参数估计是统计推断的重要组成部分.

§ 7.1 点估计

利用样本统计量及其观测值, 给出总体 X 的分布中 (一个或多个) 未知参数的估计即为 **点估计**.

定义 7.1 设 $f(x, \theta)$ 为总体 X 的分布, 其中 θ 是未知参数 (这里 θ 代表全部未知参数); X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, x_1, x_2, \dots, x_n 是该样本的一组观测值. 如果统计量 $g(X_1, X_2, \dots, X_n)$ 的观测值 $g(x_1, x_2, \dots, x_n)$ 被当作 θ 的估计值, 则称 $g(x_1, x_2, \dots, x_n)$ 是 θ 的一个**点估计值**, $g(X_1, X_2, \dots, X_n)$ 是 θ 的一个**点估计量**.

例如,

7.1.1 点估计的方法

矩估计法和最大似然估计法是两种基本的点估计方法.

1. 矩估计法

事实一: 所有分布的原点矩一般都是分布中参数的函数.

例如, 参数为 λ 的泊松分布, 其均值和方差都为 λ ; 区间 $[a, b]$ 上的均匀分布, 其均值和方差分别为 $(a+b)/2$ 和 $(b-a)^2/12$. 而期望和方差又都可以由一、二阶原点矩表示, 因此许多分布的一、二阶原点矩都是分布中未知参数的函数.

事实二: 辛钦大数定理指出, 若总体 X 的 k 阶原点矩 $E(X^k)$ ($k=1, 2, \dots$) 存在, 那么

$$A_k = \frac{1}{n} \sum_{i=1}^n X_i^k \xrightarrow{P} E(X^k). \text{ 这说明样本 } k \text{ 阶原点矩能比较好地估计总体 } X \text{ 的 } k \text{ 阶原点矩.}$$

综合两方面, 则

(1) 可以建立一个关于未知参数的方程 (若只有一个未知参数) 或方程组 (若未知参数多于一个). 具

体建立过程如下:

设 $\theta_1, \theta_2, \dots, \theta_k$ 是总体 X 分布中的全部未知参数, X 的 i ($i=1, 2, \dots, k$) 阶原点矩存在, 且 $E(X^i) = g_i(\theta_1, \theta_2, \dots, \theta_k)$, $i=1, 2, \dots, k$; 又设 X_1, X_2, \dots, X_n 是总体 X 的一个样本, x_1, x_2, \dots, x_n 是该样本的样本值, 那么令

$$g_i(\theta_1, \theta_2, \dots, \theta_k) = A_i, \quad i=1, 2, \dots, k. \quad (7.1)$$

(2) 解此方程或方程组得到的解

$$\hat{\theta}_i = \hat{\theta}_i(X_1, X_2, \dots, X_n), \quad i=1, 2, \dots, k$$

就是未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的一个点估计量, 称为**矩估计量**. 而

$$\hat{\theta}_i = \hat{\theta}_i(x_1, x_2, \dots, x_n), \quad i=1, 2, \dots, k$$

是未知参数 $\theta_1, \theta_2, \dots, \theta_k$ 的一个点估计值, 称为**矩估计值**.

这种利用样本原点矩得到未知参数的点估计的方法称为**矩估计法**.

注意: (1) 由 (7.1) 式知, 矩估计量 (或矩估计值) $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 都是 A_i ($i=1, 2, \dots, k$) 的函数, 由 $A_i = \frac{1}{n} \sum_{j=1}^n X_j^i \xrightarrow{P} E(X^i)$, $i=1, 2, \dots, k$ 知, $\hat{\theta}_1, \hat{\theta}_2, \dots, \hat{\theta}_k$ 依概率收敛于待估参数 $\theta_1, \theta_2, \dots, \theta_k$ 的真值.

(2) 如果 $E(X)$ 的表达式中不含未知参数 θ , 则求 $E(X^2)$, 直到某个 $E(X^r)$ 的表达式中含有 θ 为止.

例 7.1 (P₁₈₂) 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, x_1, x_2, \dots, x_n 为样本值, X 的均值 μ 与方差 σ^2 ($\sigma^2 \neq 0$) 均存在, 但 μ, σ^2 未知, 求 μ, σ^2 的矩估计.

解 分析: 有两个未知参数 μ 和 σ^2 , 所以需要计算总体的 1、2 阶原点矩, 建立关于 μ, σ^2 的方程组.

$E(X) = \mu, E(X^2) = \sigma^2 + \mu^2$. 令

$$\begin{cases} \mu = \frac{1}{n} \sum_{i=1}^n X_i, \\ \sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n X_i^2. \end{cases}$$

由此得 μ 和 σ^2 的一个矩估计量

$$\hat{\mu} = \bar{X}, \quad (7.2)$$

$$\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - (\bar{X})^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \quad (7.3)$$

与矩估计值

$$\hat{\mu} = \bar{x}, \quad \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 - (\bar{x})^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$

例 7.1 的结果表明, 任何总体的均值和方差的矩估计表达式均为 (7.2) 式与 (7.3) 式, 并不因总体分布的不同而有差异.

例 7.2 (P₁₈₄) 已知总体 X 的分布律为

X	1	2	3
P	θ^2	$2\theta(1-\theta)$	$(1-\theta)^2$

其中 θ ($0 < \theta < 1$) 为未知参数. 今取得一组样本值 1, 2, 1, 求 θ 的矩估计值.

解 分析: 有一个未知参数 θ , 所以只需计算总体的 1 阶原点矩, 建立关于 θ 的方程.

$$E(X) = 1 \times \theta^2 + 2 \times 2\theta(1-\theta) + 3 \times (1-\theta)^2 = -2\theta + 3.$$

令

$$-2\theta + 3 = \frac{1}{3}(1+2+1),$$

得 θ 的一个矩估计值为 $\hat{\theta} = \frac{5}{6}$.

例 7.3 (P₁₈₄) 设 X 的概率密度函数为

$$f(x) = \begin{cases} (\theta+1)x^\theta, & 0 < x < 1, \\ 0, & \text{其它,} \end{cases}$$

其中 θ ($\theta > -1$) 为未知参数; X_1, X_2, \dots, X_n 为总体 X 的一个样本, x_1, x_2, \dots, x_n 为样本的样本值. 求 θ 的矩估计.

解 $E(X) = \int_{-\infty}^{+\infty} xf(x)dx = \int_0^1 x(\theta+1)x^\theta dx = \frac{\theta+1}{\theta+2}$. 令

$$\frac{\theta+1}{\theta+2} = \frac{1}{n} \sum_{i=1}^n X_i,$$

得 θ 的矩估计量 $\hat{\theta} = \frac{2\bar{X}-1}{1-\bar{X}}$, 而 $\hat{\theta} = \frac{2\bar{x}-1}{1-\bar{x}}$ 则是 θ 的矩估计值.

矩估计法可以不涉及总体的分布类型, 但要求知道总体的原点矩, 且未知参数都可以表示为总体原点矩的函数.

2. 最大似然估计法

矩估计法可以不涉及总体的分布类型, 但分布类型其实是很有用的信息. 最大似然估计法是在总体的分布类型为已知的前提下, 利用分布类型来构造未知参数点估计的一种方法.

先来看一个例子.

设某一事件 A 在一次试验中发生的概率为 p , 而且事件 A 在连续两次的独立试验中都发生了. 假如 p 只可以取 0.6 与 0.9 中的一个, 人们则通常会认为 p 应该取 0.9. 这是因为基于这样一个简单又公认的事实: $0.6^2 < 0.9^2$.

这个例子所体现的正是最大似然估计方法的基本思想, 而这个思想基于小概率原理:

- (1) 概率很小的事件在一次试验中几乎是不出现的;
- (2) 概率很小的事件在次数很多的重复试验中几乎是一定会出现的.

根据最大似然估计方法的基本思想, 对最大似然估计法作如下表述:

设已知总体 X 的分布为 $f(x_i; \theta)$, 其中 θ 为未知参数 (这里 $f(x; \theta)$ 可为离散型随机变量的分布律, 或为连续型随机变量的概率密度函数); X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, x_1, x_2, \dots, x_n 是样本观测值. 把样本值 x_1, x_2, \dots, x_n 出现的概率称为样本似然函数, 记作 $L(\theta)$, 使 $L(\theta)$ 达到最大值的 θ 的取值 $\hat{\theta}$ 则称为 θ 的最大似然估计值. $\hat{\theta}$ 一般是 x_1, x_2, \dots, x_n 的函数, 记为 $\hat{\theta} = \hat{\theta}(x_1, x_2, \dots, x_n)$, 则 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 称为 θ 的最大似然估计量.

下面就离散型与连续型两种总体情形分别作进一步讨论.

1. X 为离散型总体

设 X 的分布律为

$$f(x; \theta) = P\{X = x\},$$

其中 θ 为未知参数. 那么由样本的独立同分布性可知, 观测值 x_1, x_2, \dots, x_n 的出现概率为

$$\begin{aligned} & P\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\} \\ &= P\{X_1 = x_1\} \cdot P\{X_2 = x_2\} \cdots P\{X_n = x_n\} \\ &= P\{X = x_1\} \cdot P\{X = x_2\} \cdots P\{X = x_n\} \\ &= \prod_{i=1}^n f(x_i; \theta), \end{aligned}$$

故总体为离散型随机变量的样本似然函数为

$$L(\theta) = \prod_{i=1}^n f(x_i; \theta). \quad (7.4)$$

习惯写法:

$$L(\theta) = P\{X = x_1\} \cdot P\{X = x_2\} \cdots P\{X = x_n\}.$$

注意: 由于 $\ln L(\theta)$ 与 $L(\theta)$ 关于 θ 同增同降, 具有相同的最大值点, 所以在许多情况下, 对 $\ln L(\theta)$ 求最大值点会比较方便.

例 7.4 (P₁₈₅) 设 $X \sim B(m, p)$, 其中 $p(0 < p < 1)$ 为未知参数; X_1, X_2, \dots, X_n 是总体 X 的样本, x_1, x_2, \dots, x_n 为样本的观测值. 求 p 的最大似然估计.

解 似然函数为

$$L(p) = \prod_{i=1}^n P\{X = x_i\} = \prod_{i=1}^n C_m^{x_i} p^{x_i} (1-p)^{m-x_i} = p^{\sum_{i=1}^n x_i} (1-p)^{nm - \sum_{i=1}^n x_i} \prod_{i=1}^n C_m^{x_i}.$$

对 $L(p)$ 取对数, 有

$$\ln L(p) = \left(\sum_{i=1}^n x_i \right) \ln p + (nm - \sum_{i=1}^n x_i) \ln(1-p) + \ln \left(\prod_{i=1}^n C_m^{x_i} \right).$$

令 $\frac{d}{dp} \ln L(p) = 0$, 即

$$\frac{1}{p} \sum_{i=1}^n x_i - \frac{1}{1-p} \left(nm - \sum_{i=1}^n x_i \right) = 0,$$

由此得 p 的最大似然估计值

$$\hat{p} = \frac{1}{nm} \sum_{i=1}^n x_i = \frac{1}{m} \bar{x}.$$

p 的最大似然估计量为

$$\hat{p} = \frac{1}{nm} \sum_{i=1}^n X_i = \frac{1}{m} \bar{X}.$$

例如, 当 $m=5, n=10$, $x_1=x_3=x_5=x_7=x_9=1$ 而其余 x_i 均为 0 时, $\bar{x}=\frac{6}{10}$, $\hat{p}=\frac{\bar{x}}{m}=\frac{3}{25}$. $\frac{3}{25}$ 即是参数 p 的一个最大似然估计值.

注意到, 当 $m=1$ 时, X 服从 0-1 分布, 这时最大似然估计值 $\hat{p}=\bar{x}$ 即是 n 次抽样中事件 A 发生的频率. 因此 **频率是概率的最大似然估计值**.

2. X 是连续型总体

设 X 的概率密度函数为 $f(x; \theta)$, 其中 θ 为未知参数, 那么由样本的独立同分布性可知, X_1, X_2, \dots, X_n 的联合概率密度函数为

$$f(x_1, x_2, \dots, x_n; \theta) = \prod_{i=1}^n f_X(x_i; \theta).$$

而“观测值 x_1, x_2, \dots, x_n 出现的概率”是样本 X_1, X_2, \dots, X_n 的取值在观测值 x_1, x_2, \dots, x_n 的非常小的邻域 G 内 (不妨设为边长分别为 $\Delta x_1, \Delta x_2, \dots, \Delta x_n$ 的 n 维立方体) 取值的概率, 而这个概率为

$$\begin{aligned} P\{(X_1, X_2, \dots, X_n) \in G\} &= \iint_{(x_1, x_2, \dots, x_n) \in G} \dots \int f(t_1, t_2, \dots, t_n; \theta) dt_1 dt_2 \dots dt_n \\ &\approx f(x_1, x_2, \dots, x_n; \theta) \Delta x_1 \Delta x_2 \dots \Delta x_n \\ &= \prod_{i=1}^n f_X(x_i; \theta) \Delta x_i = \prod_{i=1}^n f_X(x_i; \theta) \cdot \prod_{i=1}^n \Delta x_i. \end{aligned}$$

由于 $\prod_{i=1}^n \Delta x_i$ 与 θ 无关, 所以 **要使 $\prod_{i=1}^n f_X(x_i; \theta) \Delta x_i$ 达到最大值, 只须 $\prod_{i=1}^n f_X(x_i; \theta)$ 达到最大值即可**. 因此总体为连续型随机变量的样本的似然函数可设为

$$\underline{L(\theta) = \prod_{i=1}^n f_X(x_i; \theta)}. \quad (7.5)$$

例 7.5 (P₁₈₇) 设 $X \sim N(\mu, \sigma^2)$, 其中 μ, σ^2 为未知参数; X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, x_1, x_2, \dots, x_n 为样本的观测值. 求 μ, σ^2 的最大似然估计.

解 X 的概率密度函数为

$$f(x; \mu, \sigma^2) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}.$$

似然函数则为

$$L(\mu, \sigma^2) = \prod_{i=1}^n f(x_i; \mu, \sigma^2) = \prod_{i=1}^n \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x_i - \mu)^2}{2\sigma^2}} = \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^n e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}.$$

取对数, 有

$$\ln L(\mu, \sigma^2) = -n \ln(\sqrt{2\pi}) - \frac{n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2.$$

令

$$\frac{\partial \ln L(\mu, \sigma^2)}{\partial \mu} = 0, \quad \frac{\partial \ln L(\mu, \sigma^2)}{\partial \sigma^2} = 0,$$

即

$$\begin{cases} \frac{1}{\sigma^2} \sum_{i=1}^n (x_i - \mu) = 0, \\ -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^n (x_i - \mu)^2 = 0. \end{cases}$$

由此得 μ, σ^2 的最大似然估计值

$$\begin{cases} \hat{\mu} = \bar{x}, \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2. \end{cases}$$

μ, σ^2 的最大似然估计量则为

$$\begin{cases} \hat{\mu} = \bar{X}, \\ \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2. \end{cases}$$

例 7.6 (P₁₈₇) 设 X 在 $[a, b]$ 上服从均匀分布, 其中 $a, b (a < b)$ 为未知参数; X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, x_1, x_2, \dots, x_n 为样本值, 试求 a, b 的最大似然估计.

解 X 的密度函数为

$$f(x; a, b) = \begin{cases} \frac{1}{b-a}, & a \leq x \leq b, \\ 0, & \text{其它,} \end{cases}$$

似然函数则为

$$L(a, b) = \prod_{i=1}^n f(x_i, \theta) = \frac{1}{(b-a)^n}, \quad (a \leq \min_{1 \leq i \leq n} x_i \leq \max_{1 \leq i \leq n} x_i \leq b).$$

因为当 $b-a > 0$ 时, $\frac{\partial L(a, b)}{\partial a} = n(b-a)^{-(n+1)} > 0$, $\frac{\partial L(a, b)}{\partial b} = -n(b-a)^{-(n+1)} < 0$, 所以 $L(a, b)$ 关于 a 单调增, 关于 b 单调减. 因此 a 越大 b 越小, $L(a, b)$ 就越大.

考虑到每个 x_i 满足 $a \leq x_i \leq b$, 故 $a \leq \min_{1 \leq i \leq n} x_i$, $b \geq \max_{1 \leq i \leq n} x_i$, 所以当 $\hat{a} = \min_{1 \leq i \leq n} x_i$, $\hat{b} = \max_{1 \leq i \leq n} x_i$ 时, $L(a, b)$ 取到最大值 $L(\hat{a}, \hat{b})$. 因此 $\hat{a} = \min_{1 \leq i \leq n} x_i$, $\hat{b} = \max_{1 \leq i \leq n} x_i$ 分别是 a, b 的最大似然估计值, $\hat{a} = \min_{1 \leq i \leq n} X_i$, $\hat{b} = \max_{1 \leq i \leq n} X_i$ 则分别是 a, b 的最大似然估计量.

在统计问题中常常先使用最大似然估计法, 当使用不方便时, 再用矩估计法.

7.1.2 点估计量的评价准则

同一参数可以有不同的估计量, 例如, 若总体为 $U(0, \theta)$, 则 θ 的矩估计量为 $2\bar{X}$, 而最大似然估计量为 $\max_{1 \leq i \leq n} X_i$. 事实上, 任何统计量原则上都可以作为未知参数的估计量. 因此客观上就存在判断同一参数的不同估计量孰优孰劣的问题.

常见的估计量评价准则有无偏性、有效性和相合性.

1. 无偏性

“零误差”估计称为无偏估计. 什么是零误差估计?

θ 的估计量 $\hat{\theta}$ 一般是随机变量. 对于不同的样本观测值, 估计值 $\hat{\theta}$ 一般不等于 θ , 而是在 θ 的真值附近波动, 因此把 $\hat{\theta}$ 值当作 θ 会有偏差 ($\hat{\theta} - \theta$ 可以是正的, 也可以是负的). 我们希望多次测得的估计值的平均数与 θ 相差无几, 即 $\hat{\theta} - \theta$ 的平均数为零, 这相当于说, 估计量的均值是 θ . 这就是估计量的无偏性准则.

定义 7.2 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的一个估计量, 如果 $E(\hat{\theta})$ 存在, 且

$$E(\hat{\theta}) = \theta, \quad (7.6)$$

则称 $\hat{\theta}$ 为 θ 的无偏估计量, 也称 $\hat{\theta}$ 作为 θ 的估计具有无偏性; 否则称 $\hat{\theta}$ 是 θ 的有偏估计量.

定义 7.3 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的一个估计量, 如果 $E(\hat{\theta})$ 存在, 且

$$\lim_{n \rightarrow \infty} E(\hat{\theta}) = \theta, \quad (7.7)$$

则称 $\hat{\theta}$ 为 θ 的渐进无偏估计量.

无偏估计量显然是渐进无偏估计量.

例 7.7 (P₁₈₉) 设 X 的期望 μ 与方差 σ^2 存在, X_1, X_2, \dots, X_n 是来自总体 X 的一个样本, 证明: 样本均值 \bar{X} 和样本方差 S^2 分别是 μ, σ^2 的无偏估计量, 而 $S_n^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2$ 是 σ^2 的渐进无偏估计量.

证 $E(\bar{X}) = E\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} \sum_{i=1}^n \mu = \mu,$

所以样本均值 \bar{X} 是总体期望 μ 的无偏估计量.

又

$$\begin{aligned} E(S^2) &= \frac{1}{n-1} E\left[\sum_{i=1}^n (X_i - \bar{X})^2\right] = \frac{1}{n-1} E\left(\sum_{i=1}^n X_i^2 - n\bar{X}^2\right) \\ &= \frac{1}{n-1} \left(\sum_{i=1}^n E(X_i^2) - nE(\bar{X}^2)\right) \end{aligned}$$

$$= \frac{1}{n-1} \left\{ \sum_{i=1}^n [D(X_i) + (E(X_i))^2] - n [D(\bar{X}) + (E(\bar{X}))^2] \right\}$$

$$= \frac{1}{n-1} \left[n(\sigma^2 + \mu^2) - n \left(\frac{\sigma^2}{n} + \mu^2 \right) \right] = \sigma^2,$$

所以样本方差 S^2 是总体方差 σ^2 的无偏估计量.

因

$$E(S_n^2) = E\left(\frac{n-1}{n} S^2\right) = \frac{n-1}{n} E(S^2) = \frac{n-1}{n} \sigma^2,$$

故 S_n^2 不是总体方差 σ^2 的无偏估计量. 但

$$\lim_{n \rightarrow \infty} E(S_n^2) = \lim_{n \rightarrow \infty} \frac{n-1}{n} \sigma^2 = \sigma^2,$$

因此 S_n^2 是总体方差 σ^2 的渐进无偏估计量.

本例表明: 对总体 X 而言, 其样本均值 \bar{X} 是 $E(X)$ 的无偏估计量, 样本方差 S^2 是 $D(X)$ 的无偏估计量.

即

$$\underline{E(\bar{X}) = E(X), \quad E(S^2) = D(X)}.$$

例 7.8 (续例 7.6) (P₁₈₉) 当 $a=0$ 时, 证明 $\frac{n+1}{n} \hat{b}$ 是 b 的无偏估计量.

证 由 X 的分布函数

$$F(x) = \begin{cases} 0, & x < 0, \\ \frac{x}{b}, & 0 \leq x \leq b, \\ 1, & x > b \end{cases}$$

及 § 3.6 中的内容可知, \hat{b} 的分布函数为

$$F_{\hat{b}}(x) = [F(x)]^n = \begin{cases} 0, & x < 0, \\ \frac{x^n}{b^n}, & 0 \leq x \leq b, \\ 1, & x > b. \end{cases}$$

因此 \hat{b} 的密度函数为

$$f_{\hat{b}}(x) = \begin{cases} \frac{n}{b^n} x^{n-1}, & 0 \leq x \leq b, \\ 0, & \text{其它.} \end{cases}$$

由 $E(\hat{b}) = \int_{-\infty}^{+\infty} x f_{\hat{b}}(x) dx = \int_0^b \frac{n}{b^n} x^n dx = \frac{n}{n+1} b$, 有

$$E\left(\frac{n+1}{n} \hat{b}\right) = b.$$

所以 $\frac{n+1}{n} \hat{b}$ 是 b 的无偏估计量.

2. 有效性

怎样比较同一参数的多个无偏估计量孰优孰劣呢?

在样本容量相同的条件下, 设 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是参数 θ 的两个无偏估计量, 如果 $\hat{\theta}_1$ 的观测值比 $\hat{\theta}_2$ 的更集中在 θ 附近, 那么就认为 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 对 θ 的估计更好. 据此提出无偏估计量的有效性准则.

定义 7.4 设 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 都是未知参数 θ 的无偏估计量, 如果

$$D(\hat{\theta}_1) < D(\hat{\theta}_2), \quad (7.8)$$

则称 $\hat{\theta}_1$ 比 $\hat{\theta}_2$ 有效.

例 7.9 (P₁₉₀) 设 X_1, X_2, X_3 是来自 $N(\mu, \sigma^2)$ 的一个样本, 验证:

$$\hat{\mu}_1 = \frac{1}{5}X_1 + \frac{3}{10}X_2 + \frac{1}{2}X_3,$$

$$\hat{\mu}_2 = \frac{1}{3}X_1 + \frac{1}{4}X_2 + \frac{5}{12}X_3,$$

$$\hat{\mu}_3 = \frac{1}{3}X_1 + \frac{1}{3}X_2 + \frac{1}{3}X_3$$

都是 μ 的无偏估计量, 并比较它们的有效性.

解 $E(\hat{\mu}_1) = \frac{1}{5}E(X_1) + \frac{3}{10}E(X_2) + \frac{1}{2}E(X_3) = \mu,$

$$E(\hat{\mu}_2) = \frac{1}{3}E(X_1) + \frac{1}{4}E(X_2) + \frac{5}{12}E(X_3) = \mu,$$

$$E(\hat{\mu}_3) = \frac{1}{3}E(X_1) + \frac{1}{3}E(X_2) + \frac{1}{3}E(X_3) = \mu,$$

所以 $\hat{\mu}_1, \hat{\mu}_2, \hat{\mu}_3$ 都是 μ 的无偏估计量. 又

$$D(\hat{\mu}_1) = \frac{1}{25}D(X_1) + \frac{9}{100}D(X_2) + \frac{1}{4}D(X_3) = \frac{38}{100}\sigma^2,$$

$$D(\hat{\mu}_2) = \frac{1}{9}D(X_1) + \frac{1}{16}D(X_2) + \frac{25}{144}D(X_3) = \frac{50}{144}\sigma^2,$$

$$D(\hat{\mu}_3) = \frac{1}{9}D(X_1) + \frac{1}{9}D(X_2) + \frac{1}{9}D(X_3) = \frac{1}{3}\sigma^2,$$

所以 $\hat{\mu}_2$ 比 $\hat{\mu}_1$ 有效, $\hat{\mu}_3$ 比 $\hat{\mu}_2$ 有效, $\hat{\mu}_3$ 比 $\hat{\mu}_1, \hat{\mu}_2$ 都有效.

3. 相合性 (一致性)

无偏、有效的估计量是否就是好的估计量呢?

无偏性和有效性都是在样本容量为有限的前提下讨论的, 在样本容量有限的条件下, 无偏估计量的观测值一般不等于未知参数. § 6.1 中的格利文科定理指出, 样本容量越大, 经验分布函数越逼近总体分布函数. 因此希望无偏估计量的观测值随着样本容量的增大, 越来越逼近未知参数. 据此在大样本前提下提出了估计量的相合性准则.

定义 7.5 设 $\hat{\theta} = \hat{\theta}(X_1, X_2, \dots, X_n)$ 是未知参数 θ 的一个估计量, 如果对于任意的正数 ε , 有

$$\lim_{n \rightarrow \infty} P\{|\hat{\theta} - \theta| \geq \varepsilon\} = 0, \quad (7.9)$$

则称 $\hat{\theta}$ 为 θ 的相合估计量.

该定义表明, $\hat{\theta}$ 为 θ 的相合估计量是指 $\hat{\theta}$ 依概率收敛于 θ .

相合性是对估计量的一个基本要求. 不具备相合性的估计量不予考虑.

由辛钦大数定理知道, 如果 X 的 k 阶原点矩 $E(X^k) = \mu_k$ 存在, 则当 $n \rightarrow \infty$ 时, X 的样本 k 阶原点矩 $A_k = \frac{1}{n} \sum_{i=1}^n X_i^k$ 依概率收敛于 μ_k . 因此, 样本 k 阶原点矩是总体 k 阶原点矩的相合估计量, 从而矩估计量是相合估计量.

例 7.10 (P₁₉₁)

作业 (P₁₉₂): 1. -3. 5. -6. 8. -12. 4. 7. 13*. -14*.

§ 7.2 区间估计

7.2.1 置信区间

未知参数的点估计量是随机变量, 其估计值一般不等于未知参数, 估计的精度也无从衡量. 考虑由样本给出未知参数的一个估计范围 (称为估计区间), 并使其包含未知参数真值的可靠性达到一定的要求, 是对未知参数的另一种估计方法——参数的区间估计.

定义 7.6 设 X_1, X_2, \dots, X_n 是来自总体 X 的样本, X 的分布 $f(x, \theta)$ 中含有未知参数 θ . 对给定的数 $\alpha (0 < \alpha < 1)$, 若有统计量 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$ 和 $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ ($\hat{\theta}_1 < \hat{\theta}_2$) 使得

$$P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} \geq 1 - \alpha, \quad (7.10)$$

则称随机区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 是 θ 的置信度 (置信水平) 为 $1 - \alpha$ 的双侧置信区间, 称 $\hat{\theta}_1$ 和 $\hat{\theta}_2$ 是该双侧置信区间的置信下限和置信上限.

(7.10) 式的直观意义是: 反复抽样多次, 每一组样本值均可以确定一个置信区间, 由伯努利大数定理知, 在这些区间中, 包含 θ 真值的约占 $100(1 - \alpha)\%$, 不包含 θ 真值的仅占 $100\alpha\%$ 左右. 例如, 若 $\alpha = 0.01$, 反复抽样 1000 次, 那么在 1000 个置信区间中包含 θ 真值的约占 990 个, 不包含 θ 真值的约占 10 个.

置信度 $1 - \alpha$ 是指参数 θ 的真值在置信区间内的可靠程度 (可信度). 置信区间的长度则是对估计精度的度量. 置信区间的长度越短, 表示估计的精度越高. 我们一般给出的是 “最小双侧置信区间”.

置信区间原理: 按定义, 置信区间不唯一, 当 $P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} = 1 - \alpha$ 时, $(\hat{\theta}_1, \hat{\theta}_2)$ 即是一个 “最小” 双侧

置信区间，置信上限和下限是双侧 α 分位数.

容易得到分位数的随机变量主要有标准正态分布变量、 χ^2 变量、 t 变量和 F 变量，所以若仅含未知参数(如 θ)的某样本函数(如 $Y(\theta)$)是这几个变量之一，那么由

$$P\{Y_{1-\alpha/2} < Y(\theta) < Y_{\alpha/2}\} = 1 - \alpha,$$

可以等价地得到

$$P\{\hat{\theta}_1 < \theta < \hat{\theta}_2\} = 1 - \alpha,$$

于是就求得了 θ 的一个双侧置信区间 $(\hat{\theta}_1, \hat{\theta}_2)$.

例 7.11 (P₁₉₄) 设 $X \sim N(\mu, \sigma^2)$ ，其中参数 σ^2 已知，但 μ 未知， X_1, X_2, \dots, X_n 是来自总体 X 的样本，求 μ 的置信度为 0.95 的置信区间.

解 由 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$ ，令

$$P\{-z_{\alpha/2} < Z < z_{\alpha/2}\} = 1 - \alpha,$$

则有

$$P\left\{-z_{\alpha/2} < \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < z_{\alpha/2}\right\} = 1 - \alpha,$$

$$P\left\{\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2} < \mu < \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right\} = 1 - \alpha.$$

从而得到 μ 的置信度为 $1 - \alpha$ 的一个置信区间

$$\left(\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2}\right).$$

例如，若取 $\alpha = 0.05$ ，则有 $z_{\alpha/2} = z_{0.025} = 1.96$ 。当 $\sigma = 1, n = 16, \bar{x} = 5.20$ 时，有 $\frac{\sigma}{\sqrt{n}} z_{\alpha/2} = \frac{1}{\sqrt{16}} \times 1.96 = 0.49$ ，于是得到一个区间 $(4.71, 5.69)$ 。

注意： $(4.71, 5.69)$ 已不是随机区间，但习惯上仍称它为置信区间。认为 $P\{4.71 < \mu < 5.69\} = 0.95$ 是错误的。事实上，要么 $\mu \in (4.71, 5.69)$ ，此时 $P\{4.71 < \mu < 5.69\} = 1$ ；要么 $\mu \notin (4.71, 5.69)$ ，此时 $P\{4.71 < \mu < 5.69\} = 0$ 。

注意： 置信度为 $1 - \alpha$ 的置信区间不唯一。如： $\left(\bar{X} - \frac{\sigma}{\sqrt{n}} z_{0.02}, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{0.03}\right)$ 也是 μ 的置信度为 0.95 的置信区间。但前一个置信区间的长度 $2 \times \frac{\sigma}{\sqrt{n}} z_{0.025} = 3.92 \times \frac{\sigma}{\sqrt{n}}$ 比一个置信区间的长度 $\frac{\sigma}{\sqrt{n}} (z_{0.02} + z_{0.03}) = 3.94 \times \frac{\sigma}{\sqrt{n}}$ 短，前者的估计精度高于后者。

有这样一些实际问题，例如，国家幸福指数的一个指标是国民的平均寿命，寿命长是人们所希望的，国民的平均寿命不应该低于某个值。又如是在检测系统误差时，系统误差越接近 0 越好，关键的是误差的绝对值不应该超过某限定值，等等。这些问题只涉及一个上限或下限，谓之单侧区间估计问题。

若有统计量 $\hat{\theta}_3 = \hat{\theta}_3(X_1, X_2, \dots, X_n)$ 使得

$$P\{\theta < \hat{\theta}_3\} \geq 1 - \alpha,$$

则称随机区间 $(-\infty, \hat{\theta}_3)$ 是 θ 的置信度(置信水平)为 $1 - \alpha$ 的单侧置信区间, 称 $\hat{\theta}_3$ 是该单侧置信区间的单侧置信上限.

若有统计量 $\hat{\theta}_4 = \hat{\theta}_4(X_1, X_2, \dots, X_n)$ 使得

$$P\{\theta > \hat{\theta}_4\} \geq 1 - \alpha,$$

则称随机区间 $(\hat{\theta}_4, +\infty)$ 是 θ 的置信度(置信水平)为 $1 - \alpha$ 的单侧置信区间, 称 $\hat{\theta}_4$ 是该单侧置信区间的单侧置信下限.

在例 7.11 中, 若令

$$P\{Z < z_\alpha\} = 1 - \alpha,$$

则有

$$P\left\{\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} < z_\alpha\right\} = 1 - \alpha,$$
$$P\left\{\mu > \bar{X} - \frac{\sigma}{\sqrt{n}} z_\alpha\right\} = 1 - \alpha.$$

于是得到 μ 的置信度为 $1 - \alpha$ 的一个单侧置信区间

$$\left(\bar{X} - \frac{\sigma}{\sqrt{n}} z_\alpha, +\infty\right). \quad (7.11)$$

其中 $\hat{\mu} = \bar{X} - \frac{\sigma}{\sqrt{n}} z_\alpha$ 是该置信区间的置信下限.

同理可得 μ 的置信度为 $1 - \alpha$ 的另一个单侧置信区间

$$\left(-\infty, \bar{X} + \frac{\sigma}{\sqrt{n}} z_\alpha\right). \quad (7.12)$$

其中 $\hat{\mu} = \bar{X} + \frac{\sigma}{\sqrt{n}} z_\alpha$ 是该置信区间的置信上限.

求置信区间的一般步骤(单侧类似):

(1) 弄清楚已知条件, 确定要进行区间估计的未知参数(比如 θ);

(2) 寻求一个样本 X_1, X_2, \dots, X_n 的函数, 它必须含有参数 θ , 而不含其它未知参数. 该函数的分布必须已知, 且不依赖于未知参数 θ .

(3) 设 $G = g(X_1, X_2, \dots, X_n; \theta)$ 是符合(2)中条件的函数, 那么对于给定的置信度 $1 - \alpha$, 确定两个常数 λ_1, λ_2 , 使

$$P\{\lambda_1 < G < \lambda_2\} = 1 - \alpha.$$

一般选取使 $P\{G < \lambda_1\} = P\{G > \lambda_2\} = \frac{\alpha}{2}$ 成立的 λ_1, λ_2 ;

(4) 如果能由不等式 $\lambda_1 < g(X_1, X_2, \dots, X_n; \theta) < \lambda_2$ 得到如下形式的等价不等式

$$\hat{\theta}_1(X_1, X_2, \dots, X_n) < \theta < \hat{\theta}_2(X_1, X_2, \dots, X_n),$$

那么由 $\hat{\theta}_1 = \hat{\theta}_1(X_1, X_2, \dots, X_n)$, $\hat{\theta}_2 = \hat{\theta}_2(X_1, X_2, \dots, X_n)$ 所确定的区间 $(\hat{\theta}_1, \hat{\theta}_2)$ 就是 θ 的置信度为 $1-\alpha$ 的一个双侧置信区间.

当总体为正态分布时, (2) 中的函数一般在 § 6.4 中的定理 6.2、定理 6.3 和定理 6.4 中的样本函数中选, 因为这些函数的分布已知, 且它们的分位数通过查表容易得到.

7.2.2 单个正态总体均值与方差的区间估计

本小节以下均假设 X_1, X_2, \dots, X_n 是来自总体 $N(\mu, \sigma^2)$ 的样本.

1. 均值 μ 的置信区间

(1) 方差 σ^2 已知.

选 $Z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \sim N(0,1)$, μ 的置信度为 $1-\alpha$ 的一个双侧置信区间为

$$\left(\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha/2}, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha/2} \right). \quad (7.13)$$

μ 的置信度为 $1-\alpha$ 的两个单侧置信区间分别为

$$\left(-\infty, \bar{X} + \frac{\sigma}{\sqrt{n}} z_{\alpha} \right) \quad \text{和} \quad \left(\bar{X} - \frac{\sigma}{\sqrt{n}} z_{\alpha}, +\infty \right).$$

例 7.12 某车间生产滚珠的直径 $X \sim N(\mu, \sigma^2)$. 从某一天的产品中随机地抽取 6 个, 测得直径 (单位: 毫米) 如下:

14.70, 15.21, 14.90, 14.91, 15.32, 15.32.

如果已知这天产品直径的方差为 0.05, 试求这天产品直径的平均值的置信度为 0.95 的置信区间.

(2) 方差 σ^2 未知.

选 $T = \frac{\bar{X} - \mu}{S/\sqrt{n}} \sim t(n-1)$, μ 的置信度为 $1-\alpha$ 的一个双侧置信区间

$$\left(\bar{X} - \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1), \bar{X} + \frac{S}{\sqrt{n}} t_{\alpha/2}(n-1) \right). \quad (7.14)$$

μ 的置信度为 $1-\alpha$ 的单侧置信区间为

$$\left(\bar{X} - \frac{S}{\sqrt{n}} t_{\alpha}(n-1), +\infty \right) \quad \text{和} \quad \left(-\infty, \bar{X} + \frac{S}{\sqrt{n}} t_{\alpha}(n-1) \right).$$

例 7.13 有一大批罐头, 从中随机抽取 16 个, 称得它们的质量 (单位: 克) 为

506, 508, 499, 503, 504, 510, 497, 512,

514, 505, 493, 496, 506, 502, 509, 496.

设罐头的质量近似地服从正态分布, 求总体均值 μ 的置信度为 0.95 的置信区间.

2. 方差 σ^2 的置信区间

(1) 均值 μ 已知.

选 $\chi^2 = \frac{1}{\sigma^2} \sum_{i=1}^n (X_i - \mu)^2 \sim \chi^2(n)$, σ^2 的置信度为 $1-\alpha$ 的一个双侧置信区间为

$$\left(\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha/2}^2(n)}, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha/2}^2(n)} \right). \quad (7.15)$$

σ^2 的置信度为 $1-\alpha$ 的单侧置信区间为

$$\left(\frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{\alpha}^2(n)}, +\infty \right) \quad \text{和} \quad \left(0, \frac{\sum_{i=1}^n (X_i - \mu)^2}{\chi_{1-\alpha}^2(n)} \right).$$

(2) 均值 μ 未知.

选 $\chi^2 = \frac{(n-1)S^2}{\sigma^2} \sim \chi^2(n-1)$, σ^2 的置信度为 $1-\alpha$ 的一个双侧置信区间

$$\left(\frac{(n-1)S^2}{\chi_{\alpha/2}^2(n-1)}, \frac{(n-1)S^2}{\chi_{1-\alpha/2}^2(n-1)} \right). \quad (7.16)$$

σ^2 的置信度为 $1-\alpha$ 的单侧置信区间

$$\left(\frac{(n-1)S^2}{\chi_{\alpha}^2(n-1)}, +\infty \right) \quad \text{和} \quad \left(0, \frac{(n-1)S^2}{\chi_{1-\alpha}^2(n-1)} \right).$$

在实际中, 总体均值未知的情况比较常见.

例 7.14 随机地取某种炮弹 9 发做试验, 得到炮口速度的样本标准差 $s = 11 \text{ m/s}$. 设炮口速度服从正态分布. 求这种炮弹的炮口速度的标准差 σ 的置信度为 0.95 的单侧置信上限.

7.2.3 两个正态总体均值差与方差比的区间估计

在两个正态总体的情形下, 人们关心的未知参数往往是均值差 $\mu_1 - \mu_2$ 与方差比 $\frac{\sigma_1^2}{\sigma_2^2}$, 因为它们可以反映两个正态总体之间的异同.

在本小节中均假设 X_1, X_2, \dots, X_{n_1} 是来自总体 $N(\mu_1, \sigma_1^2)$ 的样本, Y_1, Y_2, \dots, Y_{n_2} 是来自总体 $N(\mu_2, \sigma_2^2)$ 的样本, 且两个样本相互独立. 以 \bar{X} , S_1^2 表示第一个总体的样本均值和样本方差, 以 \bar{Y} , S_2^2 表示第二个总体的样本均值和样本方差.

1. 均值差 $\mu_1 - \mu_2$ 的置信区间

(1) 方差 σ_1^2, σ_2^2 已知.

选 $U = \frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{\sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}} \sim N(0,1)$, $\mu_1 - \mu_2$ 的置信度为 $1-\alpha$ 的一个双侧置信区间

$$\left(\bar{X} - \bar{Y} - z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, \bar{X} - \bar{Y} + z_{\alpha/2} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right). \quad (7.17)$$

按例 7.11 的作法, 可得到均值差 $\mu_1 - \mu_2$ 的置信度为 $1-\alpha$ 的单侧置信区间

$$\left(\bar{X} - \bar{Y} - z_{\alpha} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}}, +\infty \right) \quad \text{和} \quad \left(-\infty, \bar{X} - \bar{Y} + z_{\alpha} \sqrt{\frac{\sigma_1^2}{n_1} + \frac{\sigma_2^2}{n_2}} \right).$$

例 7.15 设两个总体 $X \sim N(\mu_1, 4)$, $Y \sim N(\mu_2, 6)$, 独立地从这两个总体中分别抽取样本容量为 16 和 24 的样本, 样本均值分别为 16.9 和 15.3. 求两总体均值差 $\mu_1 - \mu_2$ 的置信度为 0.95 的置信区间.

(2) 方差 $\sigma_1^2 = \sigma_2^2 = \sigma^2$ 未知.

选 $\frac{\bar{X} - \bar{Y} - (\mu_1 - \mu_2)}{S_{\omega} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t(n_1 + n_2 - 2)$, $\mu_1 - \mu_2$ 的置信度为 $1-\alpha$ 的一个双侧置信区间为

$$\left(\bar{X} - \bar{Y} \pm t_{\alpha/2}(n_1 + n_2 - 2) S_{\omega} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right). \quad (7.18)$$

$\mu_1 - \mu_2$ 的置信度为 $1-\alpha$ 的单侧置信区间为

$$\left(\bar{X} - \bar{Y} - t_{\alpha}(n_1 + n_2 - 2) S_{\omega} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}, +\infty \right)$$

和 $\left(-\infty, \bar{X} - \bar{Y} + t_{\alpha}(n_1 + n_2 - 2) S_{\omega} \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right).$

例 7.16 为提高某一化学生产过程的得率, 希望采用一种新的催化剂. 为慎重起见, 在实验工厂先进行试验. 设采用原来的催化剂进行了 $n_1 = 8$ 次试验, 得率的平均值 $\bar{x} = 91.73$, 样本方差 $s_1^2 = 3.89$; 采用新的催化剂也进行了 $n_2 = 8$ 次试验, 得率的平均值 $\bar{y} = 93.75$, 样本方差 $s_2^2 = 4.02$. 假设两总体均服从正态分布, 方差相等, 且两样本相互独立, 试求两总体均值差 $\mu_1 - \mu_2$ 的置信度为 0.95 的单侧置信上限.

2. 方差比 $\frac{\sigma_1^2}{\sigma_2^2}$ 的置信区间

(1) 均值 μ_1, μ_2 已知.

选 $F = \frac{n_1 \sigma_1^2}{n_2 \sigma_2^2} \cdot \frac{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2}{\sum_{i=1}^{n_1} (X_i - \mu_1)^2} \sim F(n_2, n_1)$, $\frac{\sigma_1^2}{\sigma_2^2}$ 的置信度为 $1-\alpha$ 的一个双侧置信区间

$$\left(\frac{n_2}{n_1} \cdot \frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2}{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2} F_{1-\alpha/2}(n_2, n_1), \frac{n_2}{n_1} \cdot \frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2}{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2} F_{\alpha/2}(n_2, n_1) \right). \quad (7.19)$$

$\frac{\sigma_1^2}{\sigma_2^2}$ 的置信度为 $1-\alpha$ 的单侧置信区间为

$$\left(\frac{n_2}{n_1} \cdot \frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2}{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2} F_{1-\alpha}(n_2, n_1), +\infty \right) \quad \text{和} \quad \left(0, \frac{n_2}{n_1} \cdot \frac{\sum_{i=1}^{n_1} (X_i - \mu_1)^2}{\sum_{i=1}^{n_2} (Y_i - \mu_2)^2} F_{\alpha}(n_2, n_1) \right).$$

例 7.17 已知总体 $X \sim N(24, \sigma_1^2)$, $Y \sim N(20, \sigma_2^2)$, 从这两个总体中独立地抽到两组样本值:

总体 X : 23, 22, 26, 24, 22, 25;

总体 Y : 22, 18, 19, 23, 17.

求 $\frac{\sigma_1^2}{\sigma_2^2}$ 的置信度为 0.95 的置信区间.

(2) 均值 μ_1, μ_2 未知.

选 $\frac{S_1^2/S_2^2}{\sigma_1^2/\sigma_2^2} \sim F(n_1-1, n_2-1)$, $\frac{\sigma_1^2}{\sigma_2^2}$ 的置信度为 $1-\alpha$ 的一个双侧置信区间为

$$\left(\frac{S_1^2}{S_2^2} F_{1-\alpha/2}(n_2-1, n_1-1), \frac{S_1^2}{S_2^2} F_{\alpha/2}(n_2-1, n_1-1) \right). \quad (7.20)$$

$\frac{\sigma_1^2}{\sigma_2^2}$ 的置信度为 $1-\alpha$ 的单侧置信区间为

$$\left(\frac{S_1^2}{S_2^2} F_{1-\alpha}(n_2-1, n_1-1), +\infty \right) \quad \text{和} \quad \left(0, \frac{S_1^2}{S_2^2} F_{\alpha}(n_2-1, n_1-1) \right).$$

例 7.18 从甲、乙两个生产蓄电池的工厂的产品中, 分别独立地抽取一些样品, 测得这些样品的蓄电池的电容量为

甲厂: 144, 141, 138, 142, 141, 143, 138, 137;

乙厂: 142, 143, 139, 140, 138, 141, 140, 138, 142, 136.

假设两个工厂生产的蓄电池电容量分别服从正态分布 $X \sim N(\mu_1, \sigma_1^2)$ 和 $Y \sim N(\mu_2, \sigma_2^2)$, 求方差比 $\frac{\sigma_1^2}{\sigma_2^2}$ 的置信度为 $1-\alpha=0.95$ 的置信区间.

7.2.4 非正态总体参数的区间估计

对非正态总体参数作区间估计时, 寻找样本的函数遇到了很大困难. 但由中心极限定理可知, 来自总体的样本容量为 n 的样本均值 \bar{X} 近似地服从正态分布 $N(\mu, \sigma^2/n)$ (其中 μ, σ^2 是非正态总体的均值和方差). 所以当样本容量 n 充分大时, 单个正态总体均值的置信区间 (7.13) 即是 μ 的近似置信区间 (当 σ^2 未知时, 则用样本标准差 S 替代 (7.13) 式中的 σ), 并由此可以得到能用 μ 表示的参数的近似置信区间. 这种利用大样本来对非正态总体的参数作区间估计的方法称为**大样本法**.

作业 (P₂₀₆): 1. -5.